

Actividad

Descripción

(file:///C:/Users/crist/Downloads/Maria_de_Madaria_Lopez.html#Descripción)

El uso de radiografías en el ámbito medico esta ampliamente extendido. Los radiologos son los médicos que analizan las imágenes y redactan el informe sobre lo que ven. Desde hace algunos años, los algoritmos de machine learning, en especial la redes neuronales artificiales, están analizando imágenes con un gran éxito. En esta PEC se plantea la implementación de una red neuronal convolucional para clasificar radiografías en normales o con derrame. El conjunto de datos (ver zip) que vamos a utilizar consta de 350 radiografías de tórax normales (carpeta con el nombre normal) y 350 radiografías con derrame (carpeta con el nombre effusion), tomadas y seleccionadas del conjunto de datos público NIH ChestXray14:

[https://www.nih.gov/news-events/news-releases/nih-clinical-center-provides-one-largest-publicly_available-chest-x-ray-datasets-scientific-community](https://www.nih.gov/news-events/news-releases/nih-clinical-center-provides-one-largest-publicly-available-chest-x-ray-datasets-scientific-community). (<https://www.nih.gov/news-events/news-releases/nih-clinical-center-provides-one-largest-publicly%02available-chest-x-ray-datasets-scientific-community>). Como ejemplo, se presenta la imagen del fichero n99.png del grupo normal.

Empezaremos pudiendo converir el ipynb a pdf con una librerias de nbstencion

In [54]: `!jupyter nbconvert --to html`



This application is used to convert notebook files (*.ipynb)
to various other formats.

WARNING: THE COMMANDLINE INTERFACE MAY CHANGE IN FUTURE RELEASES.

Options

=====

The options below are convenience aliases to configurable class-options,
as listed in the "Equivalent to" description-line of the aliases.

To see all configurable class-options for some <cmd>, use:

<cmd> --help-all

--debug

 set log level to logging.DEBUG (maximize logging output)
 Equivalent to: [--Application.log_level=10]

--show-config

 Show the application's configuration (human-readable format)
 Equivalent to: [--Application.show_config=True]

--show-config-json

 Show the application's configuration (json format)
 Equivalent to: [--Application.show_config_json=True]

--generate-config

 generate default config file
 Equivalent to: [--JupyterApp.generate_config=True]

-y

 Answer yes to any questions instead of prompting.
 Equivalent to: [--JupyterApp.answer_yes=True]

--execute

 Execute the notebook prior to export.
 Equivalent to: [--ExecutePreprocessor.enabled=True]

--allow-errors

 Continue notebook execution even if one of the cells throws an error and include the error message in the cell output (the default behaviour is to abort conversion). This flag is only relevant if '--execute' was specified, too.

 Equivalent to: [--ExecutePreprocessor.allow_errors=True]

--stdin

 read a single notebook file from stdin. Write the resulting notebook with default basename 'notebook.*'
 Equivalent to: [--NbConvertApp.from_stdin=True]

--stdout

 Write notebook output to stdout instead of files.
 Equivalent to: [--NbConvertApp.writer_class=StdoutWriter]

File failed to load: /extensions/nbconvertZoom.js

Run nbconvert in place, overwriting the existing notebook (only

```
    relevant when converting to notebook format)
Equivalent to: [--NbConvertApp.use_output_suffix=False --NbConvertApp.export_format=notebook --FileWriter.r.build_directory=]
--clear-output
    Clear output of current file and save in place,
        overwriting the existing notebook.
Equivalent to: [--NbConvertApp.use_output_suffix=False --NbConvertApp.export_format=notebook --FileWriter.r.build_directory= --ClearOutputPreprocessor.enabled=True]
--no-prompt
    Exclude input and output prompts from converted document.
Equivalent to: [--TemplateExporter.exclude_input_prompt=True --TemplateExporter.exclude_output_prompt=True]
--no-input
    Exclude input cells and output prompts from converted document.
        This mode is ideal for generating code-free reports.
Equivalent to: [--TemplateExporter.exclude_output_prompt=True --TemplateExporter.exclude_input=True]
--log-level=<Enum>
    Set the log level by value or name.
    Choices: any of [0, 10, 20, 30, 40, 50, 'DEBUG', 'INFO', 'WARN', 'ERROR', 'CRITICAL']
    Default: 30
    Equivalent to: [--Application.log_level]
--config=<Unicode>
    Full path of a config file.
    Default: ''
    Equivalent to: [--JupyterApp.config_file]
--to=<Unicode>
    The export format to be used, either one of the built-in formats
        ['asciidoc', 'custom', 'html', 'latex', 'markdown', 'notebook', 'pdf', 'python', 'rst', 'script',
'slides']
        or a dotted object name that represents the import path for an
        `Exporter` class
    Default: 'html'
    Equivalent to: [--NbConvertApp.export_format]
--template=<Unicode>
    Name of the template file to use
    Default: ''
    Equivalent to: [--TemplateExporter.template_file]
--writer=<DottedObjectName>
    Writer class used to write the
                                                results of the conversion
    Default: 'FileWriter'
    Equivalent to: [--NbConvertApp.writer_class]
--post=<DottedOrNone>
```

```
PostProcessor class used to write the
                                results of the conversion
Default: ''
Equivalent to: [--NbConvertApp.postprocessor_class]
--output=<Unicode>
    overwrite base name use for output files.
        can only be used when converting one notebook at a time.
Default: ''
Equivalent to: [--NbConvertApp.output_base]
--output-dir=<Unicode>
    Directory to write output(s) to. Defaults
        to output to the directory of each notebook. To recover
        previous default behaviour (outputting to the current
        working directory) use . as the flag value.
Default: ''
Equivalent to: [--FilesWriter.build_directory]
--reveal-prefix=<Unicode>
    The URL prefix for reveal.js (version 3.x).
        This defaults to the reveal CDN, but can be any url pointing to a copy
        of reveal.js.
        For speaker notes to work, this must be a relative path to a local
        copy of reveal.js: e.g., "reveal.js".
        If a relative path is given, it must be a subdirectory of the
        current directory (from which the server is run).
        See the usage documentation
        (https://nbconvert.readthedocs.io/en/latest/usage.html#reveal-js-html-slideshow)
        for more details.
Default: ''
Equivalent to: [--SlidesExporter.reveal_url_prefix]
--nbformat=<Enum>
    The nbformat version to write.
        Use this to downgrade notebooks.
Choices: any of [1, 2, 3, 4]
Default: 4
Equivalent to: [--NotebookExporter.nbformat_version]
```

Examples

The simplest way to use nbconvert is

```
> jupyter nbconvert mynotebook.ipynb
```

File failed to load: /extensions/MathZoom.js

which will convert `mynotebook.ipynb` to the default format (probably HTML).

You can specify the export format with `--to`.

Options include `['asciidoc', 'custom', 'html', 'latex', 'markdown', 'notebook', 'pdf', 'python', 'rst', 'script', 'slides']`.

```
> jupyter nbconvert --to latex mynotebook.ipynb
```

Both HTML and LaTeX support multiple output templates. LaTeX includes `'base'`, `'article'` and `'report'`. HTML includes `'basic'` and `'full'`. You can specify the flavor of the format used.

```
> jupyter nbconvert --to html --template basic mynotebook.ipynb
```

You can also pipe the output to `stdout`, rather than a file

```
> jupyter nbconvert mynotebook.ipynb --stdout
```

PDF is generated via LaTeX

```
> jupyter nbconvert mynotebook.ipynb --to pdf
```

You can get (and serve) a Reveal.js-powered slideshow

```
> jupyter nbconvert myslides.ipynb --to slides --post serve
```

Multiple notebooks can be given at the command line in a couple of different ways:

```
> jupyter nbconvert notebook*.ipynb  
> jupyter nbconvert notebook1.ipynb notebook2.ipynb
```

or you can specify the notebooks list in a config file, containing::

```
c.NbConvertApp.notebooks = ["my_notebook.ipynb"]
```

```
> jupyter nbconvert --config mycfg.py
```

To see all available configurables, use `--help-all`.

Enunciado

1. Desempaquetar y leer el fichero de datos



Empezaremos uniendo nuestro archivo ipynb a nuestro google drive, donde tenemos nuestras imagenes de derrame pulmonar

```
In [3]: # Necesitaremos montar su disco usando los siguientes comandos:  
# Para obtener más información sobre el montaje, puedes consultar: https://stackoverflow.com/questions/469863  
98/import-data-into-google-colaboratory
```

```
from google.colab import drive  
drive.mount('/content/drive')
```

Mounted at /content/drive

Cargamos las librerias que vamos a usar

```
In [4]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import cv2
import os
import random
import tensorflow as tf
from tensorflow import keras
import keras.backend as K
from keras.models import Sequential
from keras.layers import Dense, Dropout, Flatten, Activation
from keras.layers import SeparableConv2D, ZeroPadding2D, Conv2D, MaxPool2D, BatchNormalization
from keras.callbacks import ModelCheckpoint, ReduceLROnPlateau
from keras.optimizers import Adam
import matplotlib.image as mpimg
from keras.preprocessing.image import ImageDataGenerator
from sklearn.metrics import ConfusionMatrixDisplay
from sklearn.metrics import accuracy_score, confusion_matrix
from tensorflow.keras.models import Sequential, Model
from tensorflow.keras.layers import Input, Dense, Conv2D, MaxPooling2D, Flatten, Dropout
from sklearn.metrics import classification_report, confusion_matrix
from sklearn.preprocessing import LabelEncoder
```

Cargamos nuestra carpeta con las imagenes de effusion y de pacientes normales

```
In [5]: inputdir = "/content/drive/MyDrive/Pec_CNN/"
path_imagen = inputdir + "imagenes"
imagen_normal = os.path.join(path_imagen + '/normal')
imagen_effusion = os.path.join(path_imagen + '/effusion')
```

Imprimimos, cuantas imagenes tenemos de cada carpeta tanto las imagenes de pacientes normales, como pacientes patologicos

```
In [6]: print("Total number of normal images in training set: ",len(os.listdir(imagen_normal)))
print("Total number of effusion images in training set: ",len(os.listdir(imagen_effusion)))
```

Total number of normal images in training set: 350

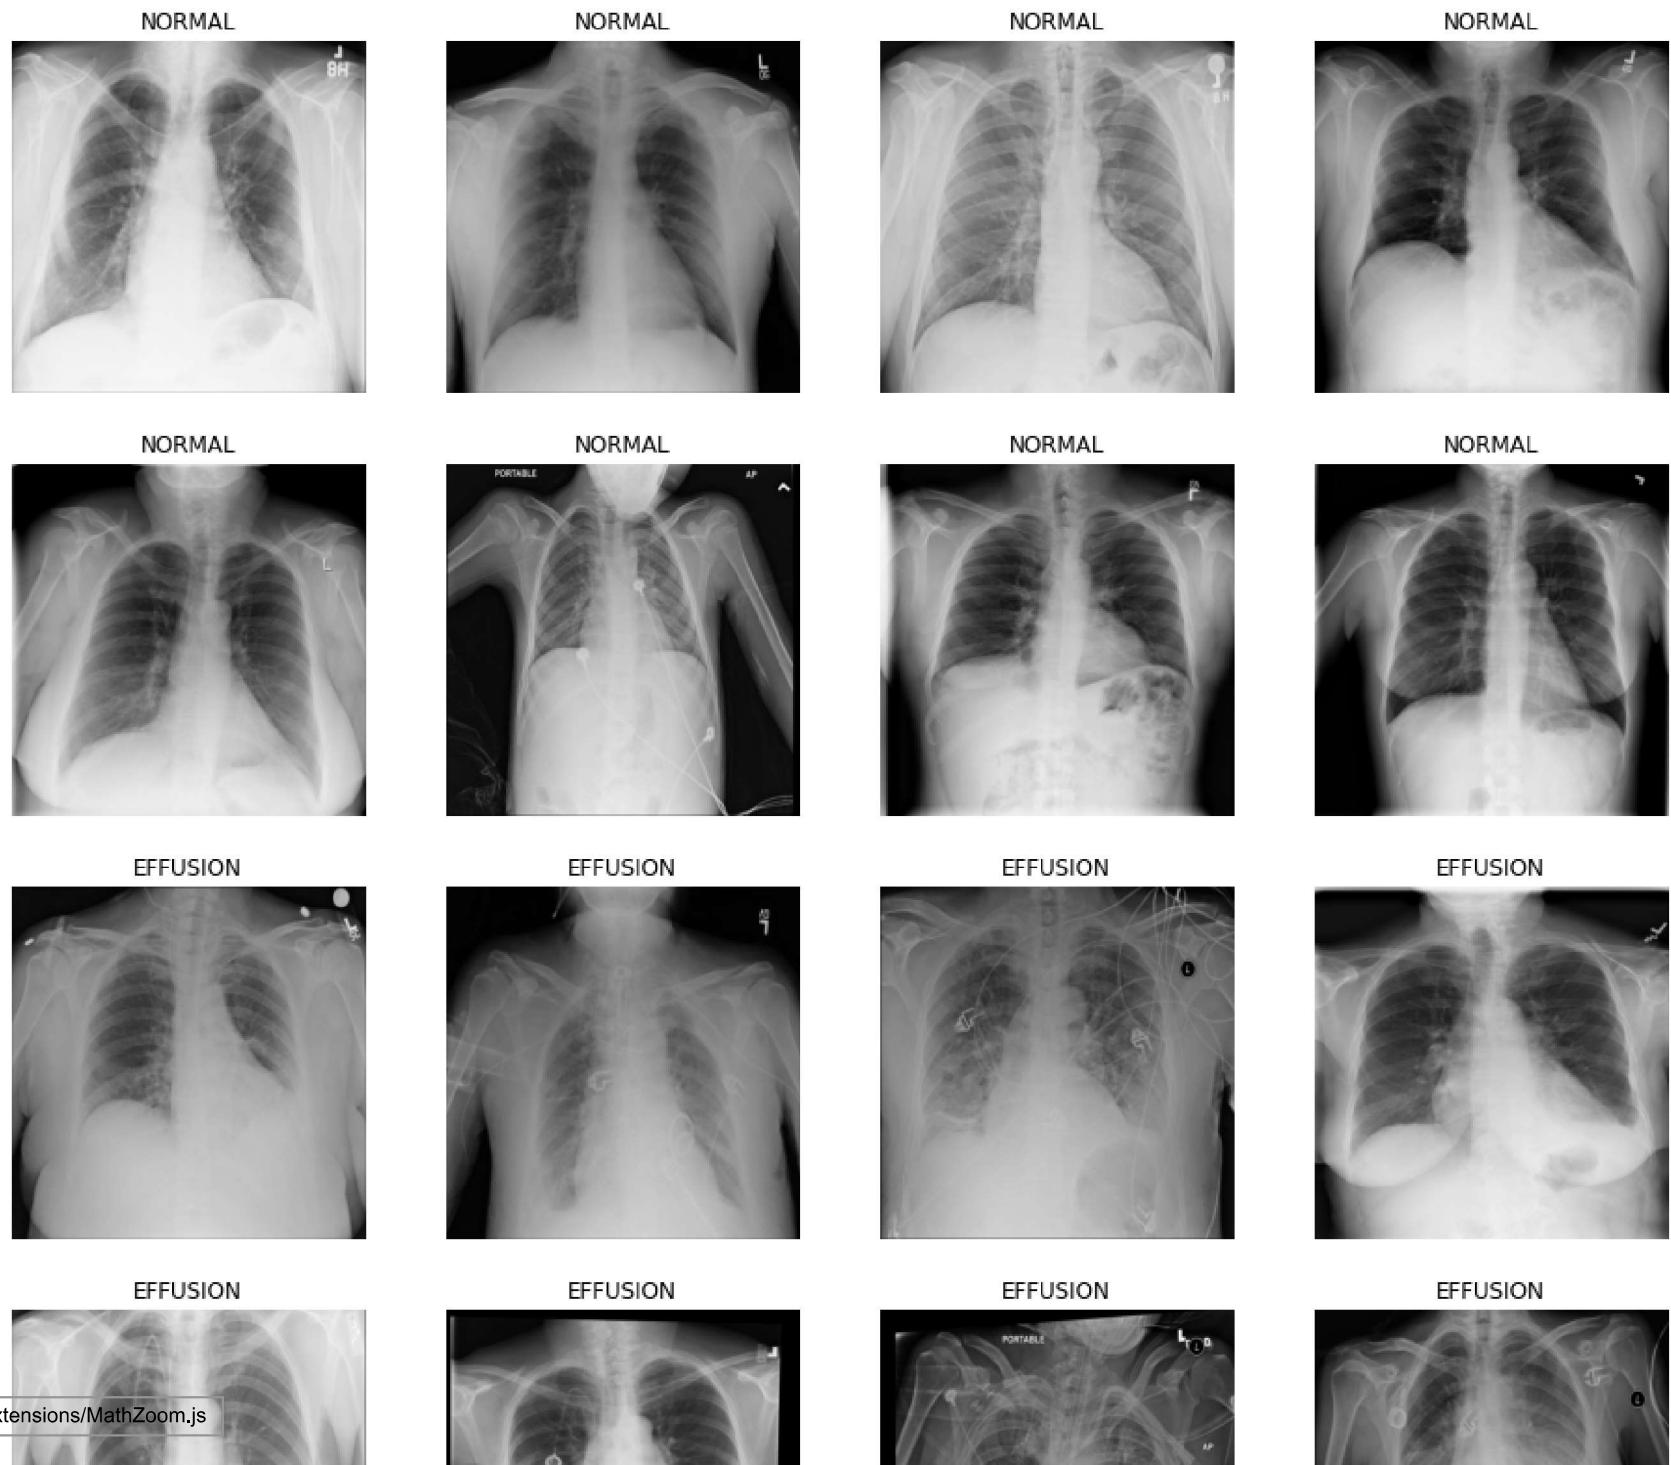
File failed to load: /ext/samples/normals/00000000000000000000000000000000.jpg
Total number of effusion images in training set: 350

Como vemos tenemos 350 imágenes en la carpeta de pacientes sanos y 350 imágenes en la carpeta de pacientes effusion

2. Presentar algunas imágenes de radiografías normales y con derram

Vamos a imprimir unas imágenes tanto de pacientes sanos, como pacientes effusion(con derrame)

```
In [7]: # Parámetros para nuestro gráfico; generaremos imágenes en una configuración 4x4
nrows = 4
ncols = 4
# Set up matplotlib fig, and size it to fit 4x4 pics
fig = plt.gcf()
fig.set_size_inches(ncols * 4, nrows * 4)
next_normal_pix = [os.path.join(imagen_normal, fname) for fname in os.listdir(imagen_normal)[0:8]]
next_effusion_pix = [os.path.join(imagen_effusion, fname) for fname in os.listdir(imagen_effusion)[0:8]]
for i, img_path in enumerate(next_normal_pix+next_effusion_pix):
    # Set up subplot; subplot indices start at 1
    sp = plt.subplot(nrows, ncols, i + 1)
    sp.axis('Off') # No mostrar ejes (o Líneas de cuadricula)
    img = mpimg.imread(img_path)
    if i<=7 :
        sp.title.set_text('NORMAL')
    else :
        sp.title.set_text('EFFUSION')
    plt.imshow(img)
plt.show()
```



File failed to load: /extensions/MathZoom.js



Como podemos ver en las imágenes, son bastante llamativas las diferencias entre pacientes normales y con derramen(effusion)

In [8]: next_normal_pix,next_effusion_pix## Veo Las imágenes que he impreso

Out[8]: (['/content/drive/MyDrive/Pec_CNN/imagenes/normal/n10.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/normal/n114.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/normal/n119.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/normal/n112.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/normal/n123.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/normal/n104.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/normal/n107.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/normal/n11.png'],
['/content/drive/MyDrive/Pec_CNN/imagenes/effusion/e108.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/effusion/e109.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/effusion/e1.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/effusion/e105.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/effusion/e100.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/effusion/e104.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/effusion/e103.png',
'/content/drive/MyDrive/Pec_CNN/imagenes/effusion/e107.png'])

Miro que contenga 512 pixeles, tanto de largo como de ancho y 3 canales, que reducire en el siguiente apartado a 1, ya que es una imagen en blanco y negro

In [9]: imagen_normal_10 = cv2.imread("/content/drive/MyDrive/Pec_CNN/imagenes/normal/n10.png")
imagen_effusion_108= cv2.imread("/content/drive/MyDrive/Pec_CNN/imagenes/effusion/e108.png")

Miro que contenga 512 pixeles, tanto de largo como de ancho y 3 canales, que reducire en el siguiente apartado a 1, ya que es una imagen en blanco y negro

File failed to load: /extensions/MathZoom.js

```
In [10]: imagen_normal_10.shape, imagen_effusion_108.shape
```

```
Out[10]: ((512, 512, 3), (512, 512, 3))
```

Como vemos todo esta correcto

3. Preprocesar las imágenes originales de 512x512x3 para convertirlas 64x64x1.

Solo se coge un canal de los 3 canales originales porque las imágenes son en blanco y negro. Todos los canales tienen la misma información

Crearemos una función que nos permita etiquetar las imágenes, y cambiar el tamaño de estas de 512 a 64, y también, tendremos un solo canal.

```
In [11]: def loadImages(path, urls, target): # Colocamos Las etiquetas
    images = [] # Tuna lista vacia que contendra las imagenes
    labels = [] # Otra lista vacia que contendra las etiquetas

    for i in range(len(urls)):
        img_path = path + "/" + urls[i] # Esto dara lugar a leer las imagenes una a una
        img = cv2.imread(img_path, 0) # Al poner 0 cambiamos el canal
        img = cv2.resize(img, (64, 64)) # Cambiamos las dimensiones de las imagenes
        images.append(img) # Iremos añadiendo las imagenes una a una
        labels.append(target) # Ponemos la etiqueta de la imagen
    images = np.asarray(images)
    return images, labels
```

```
In [12]: imagen_normal = os.path.join(path_imagen + '/normal')
imagen_effusion = os.path.join(path_imagen + '/effusion')
```

```
In [13]: normal_directory= os.listdir(imagen_normal)
effusion_directory= os.listdir(imagen_effusion)
```

```
In [14]: print("Total number of normal images in training set: ",len(os.listdir(imagen_normal)))
print("Total number of effusion images in training set: ",len(os.listdir(imagen_effusion)))
```

```
Total number of normal images in training set: 350
Total number of effusion images in training set: 350
```

Vale ahora voy a introducir la funcion loadImagen, dentro de imge_normal junto con normal_directory y señalare la etiqueta que corresponde con paciente sano

```
In [15]: Imagen_Normal, TargetNormal = loadImages(imagen_normal,normal_directory, 0)
```

Hacemos lo mismo con las imagenes de pacientes de hedema, pero cambiasmos la etiqueta a 1

```
In [16]: Imagen_Effusion, TargetEffusion = loadImages(imagen_effusion,effusion_directory, 1)
```

```
In [17]: len(normal_directory)
```

```
Out[17]: 350
```

```
In [18]: len(effusion_directory)
```

```
Out[18]: 350
```

```
In [19]: len(Imagen_Normal)
```

```
Out[19]: 350
```

```
In [20]: len(Imagen_Effusion)
```

```
Out[20]: 350
```

Comprobamos con la Imagen_Normal, que el tamaño de nuestra foto ha cambiado, ya no tenemos fotos de 512, sino tenemos fotos de 64 pixeles, , tambien podemos verlo en las imagenes de Effusion o Derrame

```
In [21]: Imagen_Normal.shape,Imagen_Effusion.shape
```

```
Out[21]: ((350, 64, 64), (350, 64, 64))
```

4. Normalizar mediante la transformación min-max las imágenes

Podemos normalizar los datos de dos formas, o con el min y maximo que tenemos un ejemplo

https://gitlab.uoclabs.uoc.es/machinelearningbioinformatics/machine-learning-bioinformatics/-/blob/master/5_NeuralNetworks/CNN_MNIST.ipynb (https://gitlab.uoclabs.uoc.es/machinelearningbioinformatics/machine-learning-bioinformatics/-/blob/master/5_NeuralNetworks/CNN_MNIST.ipynb), o dividiendo entre 255 que es el numero maximo de pixeles. Empezaremos con la funcion np.r que es una permutación que se refiere al proceso de organizar todos los individuos de un conjunto dado para formar una secuencia.

```
In [22]: datos= np.r_[Imagen_Normal,Imagen_Effusion]
```

Estoy organizando en un mismo conjunto de datos que llamo datos tanto las imagenes de Imagen_Normal con Imagen_effusion, y como puedo comprobar es la suma de ambas carpetas con un numero de 700 imagenes con un tamaño de 64pixels cada una

```
In [23]: datos.shape
```

```
Out[23]: (700, 64, 64)
```

Hacemos lo mismo con las etiquetas, que previamente hemos concatenado, y obtenemos 700 etiquetas

File failed to load: /extensions/MathZoom.js

```
In [24]: targets = np.r_[TargetNormal,TargetEffusion]
```

```
In [25]: targets.shape
```

```
Out[25]: (700,)
```

Aqui lo que vamos a hacer es sacar el maximo y el minimo, en la pregunta nos indica, lo saquemos con el maxim y el minimo, pongo un link de un repositorio de uno de los docentes, donde nos explica como se realiza https://gitlab.uoclabs.uoc.es/machinelearningbioinformatics/machine-learning-bioinformatics/-/blob/master/5_NeuralNetworks/CNN_MNIST.ipynb (https://gitlab.uoclabs.uoc.es/machinelearningbioinformatics/machine-learning-bioinformatics/-/blob/master/5_NeuralNetworks/CNN_MNIST.ipynb)

```
In [26]: # Encontramos Los valores minimos y maximos para el set del training
v_min = np.min(datos)
v_max = np.max(datos)
print("Min. and max. values before normalization are {} and {}".format(v_min, v_max))

# Normalizamos
datos_Norm = (datos - v_min) / (v_max - v_min)

print("Min. and max. values after normalization are {} and {}".format(np.min(datos_Norm), np.max(datos_Norm)))
```

```
Min. and max. values before normalization are 0 and 255.
```

```
Min. and max. values after normalization are 0.0 and 1.0.
```

Vamos a imprimir la base normalizada y concatenada, para comprobar que los datos estan entre 1 y 0

```
In [27]: print(datos_Norm)
```

```

[[[0.02745098 0.02745098 0.05882353 ... 0.03529412 0.03921569 0.0745098 ]
 [0.02352941 0.1372549 0.19215686 ... 0.03137255 0.03529412 0.06666667]
 [0.15294118 0.24313725 0.3254902 ... 0.11372549 0.03137255 0.05882353]
 ...
 [0.82745098 0.88235294 0.89411765 ... 0.61960784 0.67058824 0.85098039]
 [0.82352941 0.8745098 0.89803922 ... 0.43529412 0.57647059 0.77254902]
 [0.84313725 0.88627451 0.91372549 ... 0.42745098 0.56470588 0.68627451]]]

[[[0.01568627 0.01568627 0.01568627 ... 0.01176471 0.01176471 0.01176471]
 [0.01568627 0.01568627 0.01176471 ... 0.01176471 0.01176471 0.01176471]
 [0.01176471 0.01176471 0.01176471 ... 0.01176471 0.01176471 0.01176471]
 ...
 [0.2745098 0.07843137 0.00784314 ... 0.01176471 0.01568627 0.01176471]
 [0.21176471 0.05882353 0.00784314 ... 0.01176471 0.01176471 0.01176471]
 [0.17254902 0.03529412 0.00784314 ... 0.01176471 0.01176471 0.01176471]]]

[[[0.0745098 0.07058824 0.06666667 ... 0.16862745 0.03529412 0.03921569]
 [0.07058824 0.07058824 0.0627451 ... 0.2745098 0.20392157 0.11764706]
 [0.0627451 0.0627451 0.04705882 ... 0.51764706 0.2745098 0.21176471]
 ...
 [0.16078431 0.30588235 0.41568627 ... 0.54509804 0.41568627 0.25882353]
 [0.15686275 0.29411765 0.40392157 ... 0.5372549 0.39607843 0.23137255]
 [0.15294118 0.2627451 0.38431373 ... 0.52156863 0.38039216 0.21960784]]]

...
[[0. 0. 0. ... 0. 0. 0.]
 [0. 0. 0. ... 0. 0. 0.]
 [0. 0.00392157 0.05098039 ... 0. 0. 0.]
 ...
 [0.27058824 0.35294118 0.40784314 ... 0.18039216 0.09803922 0.05882353]
 [0.27843137 0.36078431 0.41960784 ... 0.2 0.14901961 0.05490196]
 [0.34901961 0.4 0.43921569 ... 0.21960784 0.16862745 0.05490196]]]

[[[0.02745098 0.03137255 0.03137255 ... 0.03137255 0.03137255 0.03137255]
 [0.30980392 0.03137255 0.03137255 ... 0.03137255 0.03137255 0.03137255]
 [0.05882353 0.03137255 0.03137255 ... 0.03137255 0.03137255 0.03137255]
 ...
 [0.40784314 0.38431373 0.35294118 ... 0.05882353 0.06666667 0.06666667]
 [0.38823529 0.38431373 0.35294118 ... 0.0627451 0.0627451 0.06666667]
 [0.36078431 0.43137255 0.37254902 ... 0.0627451 0.07843137 0.06666667]]]

[[0.00784314 0.00784314 0.00784314 ... 0.01176471 0.01176471 0.01176471]]

```

```
[0.00784314 0.00784314 0.00784314 ... 0.01176471 0.01176471 0.01176471]
[0.00784314 0.00784314 0.00784314 ... 0.01176471 0.01176471 0.01176471]
...
[0.08235294 0.01176471 0.21568627 ... 0.87058824 0.87058824 0.84313725]
[0.12156863 0.01960784 0.39215686 ... 0.87843137 0.8745098 0.85882353]
[0.02745098 0.49019608 0.43529412 ... 0.89803922 0.89411765 0.87058824]]]
```

Como comprobamos los vvalores que tenemos estan normalizados entre 1 y 0

5. Dividir el conjunto de datos en 600 train y 100 de test. Tratar de equilibrar las dos clases.

Dividiremos el dataset como nos indica la pregunta 5, para eso usaaremos la libreria se scikit_learn https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html (https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html), esta libreria nos permite, dividir en entrenamiento y test los datos que hemos concatenado y normalizado en el punto anterior

```
In [28]: from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(datos_Norm, targets, test_size=0.1428)
```

Miraremos con la funcion shape, como se ha dividido nuestras base normalizada tanto en trenamiento como en test, y dividiremos x_train como x_test para entrenar y tendra toda la informacion de todas las imagenes tanto de pacientes normales, como de pacientes con hemorragia o (effusion)

```
In [29]: x_train.shape,y_train.shape,x_test.shape,y_test.shape
```



```
Out[29]: ((600, 64, 64), (600,), (100, 64, 64), (100,))
```

Como vemos coincide a la perfección con lo que se nos pide en el enunciado, las partes de entrenamiento contienen 600 imágenes y etiquetas, y la parte de test contienen 100 imágenes y etiquetas

Como vemos las X que son las encargadas del entrenamiento y de test, ambas contienen la información de todas las imágenes sin las etiquetas, usaremos la función reshape, para que conserven su formato de array

```
In [31]: x_train = x_train.reshape(600,64,64)
x_test = x_test.reshape(100,64,64)

print("datos de entrenamiento: {}".format(x_train.shape))
print("datos de test: {}".format(x_test.shape))

datos de entrenamiento: (600, 64, 64)
datos de test: (100, 64, 64)
```

Como vemos tiene la división correcta y el tamaño de las imágenes

Como podemos ver tiene el tamaño que se nos pide, y con la librería de keras, pasamos los vectores a matrices binarias, esto nos ayudará en el siguiente paso que es la red neuronal.

```
In [32]: from keras.utils import to_categorical
y_train = to_categorical(y_train)
y_test = to_categorical(y_test)

print("forma de y_train {} y el valor de y_train[0] es {}".format(y_train.shape,y_train[0]))
print("forma de y_test es {} y el valor de y_test[0] es {}".format(y_test.shape, y_test[1]))

forma de y_train (600, 2) y el valor de y_train[0] es [0. 1.]
forma de y_test es (100, 2) y el valor de y_test[0] es [1. 0.]
```

Como podemos ver, la matriz que obtenemos en y_train e y_test es una matriz binaria debido a la función de keras

6. Implementa dos redes neuronales convolucionales (CNN) con distintas arquitecturas siguiendo las instrucciones siguientes:*

- El número de capas convolucionales no debe ser superior a 6.
 - Deben incluirse capas de agrupación(pool layers) para reducir el número de parámetros.
 - En la parte inferior de la red, las capas totalmente conectadas tendrán 128 y 32 nodos, respectivamente.
- *- Capa de salida con activación 'sigmoide'.**
- Los parámetros entrenables deben ser al menos 60000.

```
In [36]: num_classes = 2
model_1 = Sequential() ## Creamos el primer modelo
# Añadimos la 1ª capa de convolución
model_1.add(Conv2D(32, kernel_size=3, activation="relu", input_shape=(64,64,1)))# formamos la primera capa convolucionarial, con el tamaño de las imágenes
model_1.add(MaxPooling2D((2,2), padding="same"))# Vamos a agrupar los datos
model_1.add(Conv2D(16, kernel_size=3, activation="relu"))# ponemos la 2ª capa de convolución
model_1.add(Flatten()) #Ponemos la capa de flatten para reducir la entrada
# Añadimos las capas totalmente conectadas
model_1.add(Dense(128, activation="relu")) ## Añadimos las primeras 128 capas
model_1.add(Dense(32, activation="relu")) ## Ponemos 32 capas
model_1.add(Dense(num_classes, activation="sigmoid"))#Ponemos capa de salida
```

Creamos la segunda red neuronal o modelo

```
In [37]: num_classes = 2
model_2 = Sequential()## creamos el primer modelo
model_2.add(Conv2D(32, kernel_size=3, activation="relu", input_shape=(64,64,1)))# formamos la primera capa convolucional, junto con el tamaño de las imagenes
model_2.add(MaxPooling2D((2,2), padding="same"))# Vamos a agrupar los datos
# Añadimos la 2ª capa de convolución
model_2.add(Conv2D(16, kernel_size=3, activation="relu"))# Ponemos la segunda convolucion con 16 capas
model_2.add(MaxPooling2D((2,2), padding="same"))# Las volvemos a agrupar
# Añadimos la 3ª capa de convolución
model_2.add(Conv2D(8, kernel_size=3, activation="relu"))# # Añadimos la 3ª capa de convolución con 8 capas
model_2.add(Flatten())
model_2.add(Dense(128, activation="relu"))
model_2.add(Dense(32, activation="relu"))
model_2.add(Dense(num_classes, activation="sigmoid"))# Añadimos capa de salida, con activacion sigmoide como se nos pide en el enunciado
```

Vamos a compilar el modeloCNN, de la primera red neuronal que hemos creado, e imprimimos el modelo

```
In [38]: model_1.compile(optimizer='adam', loss='categorical_crossentropy', metrics=[ 'accuracy' ])
```

```
In [39]: print(model_1.summary())
```

Model: "sequential_1"

Layer (type)	Output Shape	Param #
<hr/>		
conv2d_3 (Conv2D)	(None, 62, 62, 32)	320
max_pooling2d_2 (MaxPooling 2D)	(None, 31, 31, 32)	0
conv2d_4 (Conv2D)	(None, 29, 29, 16)	4624
flatten_1 (Flatten)	(None, 13456)	0
dense_3 (Dense)	(None, 128)	1722496
dense_4 (Dense)	(None, 32)	4128
dense_5 (Dense)	(None, 2)	66
<hr/>		
Total params: 1,731,634		
Trainable params: 1,731,634		
Non-trainable params: 0		
<hr/>		
None		

Como podemos ver nuestra red neuronal compila 1,731,634, y en el enunciado nos pedia 60.000, asi que nuestro modelo compila mas datos para posteriormente ser entrenados

Compilamos la segunda red neuronal o modelo,m y una vez tengo compilados los 2 entreno las 2 redes neruionales y hare las curva Roc y podre sacar la prediccion

```
In [42]: model_2.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
```

```
In [43]: print(model_2.summary())
```

Model: "sequential_2"

Layer (type)	Output Shape	Param #
<hr/>		
conv2d_5 (Conv2D)	(None, 62, 62, 32)	320
max_pooling2d_3 (MaxPooling 2D)	(None, 31, 31, 32)	0
conv2d_6 (Conv2D)	(None, 29, 29, 16)	4624
max_pooling2d_4 (MaxPooling 2D)	(None, 15, 15, 16)	0
conv2d_7 (Conv2D)	(None, 13, 13, 8)	1160
flatten_2 (Flatten)	(None, 1352)	0
dense_6 (Dense)	(None, 128)	173184
dense_7 (Dense)	(None, 32)	4128
dense_8 (Dense)	(None, 2)	66
<hr/>		
Total params: 183,482		
Trainable params: 183,482		
Non-trainable params: 0		
<hr/>		
None		

Vamos a entrenar las dos redes neuronales, empezaremos entrenando el primer modelo o red neuronal y seguidamente entrenaremos la segunda red neuronal

In [44]: # Empezamos entrenando la primera red neuronal

```
n_epochs = 25
mfit_1= model_1.fit(x_train, y_train, validation_data=(x_test, y_test), batch_size=10, epochs=n_epochs)
```

Epoch 1/25
60/60 [=====] - 9s 8ms/step - loss: 0.6462 - accuracy: 0.6117 - val_loss: 0.5612 - val_accuracy: 0.7700
Epoch 2/25
60/60 [=====] - 0s 7ms/step - loss: 0.6096 - accuracy: 0.6650 - val_loss: 0.6452 - val_accuracy: 0.5900
Epoch 3/25
60/60 [=====] - 0s 7ms/step - loss: 0.5510 - accuracy: 0.7283 - val_loss: 0.5085 - val_accuracy: 0.7300
Epoch 4/25
60/60 [=====] - 0s 6ms/step - loss: 0.5210 - accuracy: 0.7483 - val_loss: 0.5613 - val_accuracy: 0.7000
Epoch 5/25
60/60 [=====] - 0s 6ms/step - loss: 0.4944 - accuracy: 0.7733 - val_loss: 0.4800 - val_accuracy: 0.7800
Epoch 6/25
60/60 [=====] - 0s 5ms/step - loss: 0.4390 - accuracy: 0.8083 - val_loss: 0.4160 - val_accuracy: 0.8300
Epoch 7/25
60/60 [=====] - 0s 6ms/step - loss: 0.4000 - accuracy: 0.8233 - val_loss: 0.4816 - val_accuracy: 0.8000
Epoch 8/25
60/60 [=====] - 0s 6ms/step - loss: 0.3889 - accuracy: 0.8350 - val_loss: 0.5141 - val_accuracy: 0.7400
Epoch 9/25
60/60 [=====] - 0s 6ms/step - loss: 0.3538 - accuracy: 0.8450 - val_loss: 0.4174 - val_accuracy: 0.8300
Epoch 10/25
60/60 [=====] - 0s 7ms/step - loss: 0.3031 - accuracy: 0.8767 - val_loss: 0.5679 - val_accuracy: 0.8400
Epoch 11/25
60/60 [=====] - 0s 5ms/step - loss: 0.3122 - accuracy: 0.8633 - val_loss: 0.4817 - val_accuracy: 0.8400
Epoch 12/25
60/60 [=====] - 0s 5ms/step - loss: 0.2976 - accuracy: 0.8900 - val_loss: 0.4023 - val_accuracy: 0.8600
Epoch 13/25
60/60 [=====] - 0s 4ms/step - loss: 0.2121 - accuracy: 0.9233 - val_loss: 0.5068 - val_accuracy: 0.8300
Epoch 14/25
60/60 [=====] - 0s 5ms/step - loss: 0.1750 - accuracy: 0.9283 - val_loss: 0.6625 - val_accuracy: 0.7700
Epoch 15/25

File failed to load: /experiments/mnist_jp.7700

```
60/60 [=====] - 0s 4ms/step - loss: 0.1883 - accuracy: 0.9333 - val_loss: 0.6369 - val_accuracy: 0.8500
Epoch 16/25
60/60 [=====] - 0s 5ms/step - loss: 0.1266 - accuracy: 0.9517 - val_loss: 0.6574 - val_accuracy: 0.8400
Epoch 17/25
60/60 [=====] - 0s 4ms/step - loss: 0.1053 - accuracy: 0.9650 - val_loss: 0.6087 - val_accuracy: 0.8400
Epoch 18/25
60/60 [=====] - 0s 5ms/step - loss: 0.1047 - accuracy: 0.9517 - val_loss: 0.6985 - val_accuracy: 0.8200
Epoch 19/25
60/60 [=====] - 0s 5ms/step - loss: 0.0810 - accuracy: 0.9700 - val_loss: 0.8110 - val_accuracy: 0.8100
Epoch 20/25
60/60 [=====] - 0s 4ms/step - loss: 0.0656 - accuracy: 0.9783 - val_loss: 0.7178 - val_accuracy: 0.8600
Epoch 21/25
60/60 [=====] - 0s 4ms/step - loss: 0.0354 - accuracy: 0.9933 - val_loss: 0.9385 - val_accuracy: 0.7800
Epoch 22/25
60/60 [=====] - 0s 4ms/step - loss: 0.0226 - accuracy: 0.9917 - val_loss: 0.9306 - val_accuracy: 0.8300
Epoch 23/25
60/60 [=====] - 0s 4ms/step - loss: 0.0093 - accuracy: 0.9983 - val_loss: 1.1845 - val_accuracy: 0.8100
Epoch 24/25
60/60 [=====] - 0s 4ms/step - loss: 0.0362 - accuracy: 0.9867 - val_loss: 1.0874 - val_accuracy: 0.7900
Epoch 25/25
60/60 [=====] - 0s 4ms/step - loss: 0.0897 - accuracy: 0.9633 - val_loss: 0.9218 - val_accuracy: 0.8300
```

```
In [45]: ## Entrenamos la segunda red neuronal
n_epochs = 25
mfit_2 = model_2.fit(x_train, y_train, validation_data=(x_test, y_test), batch_size=10, epochs=n_epochs)
```

Epoch 1/25
60/60 [=====] - 1s 7ms/step - loss: 0.6691 - accuracy: 0.5550 - val_loss: 0.5508 - val_accuracy: 0.7500
Epoch 2/25
60/60 [=====] - 0s 5ms/step - loss: 0.5710 - accuracy: 0.7250 - val_loss: 0.4928 - val_accuracy: 0.7800
Epoch 3/25
60/60 [=====] - 0s 4ms/step - loss: 0.4998 - accuracy: 0.7600 - val_loss: 0.4584 - val_accuracy: 0.8100
Epoch 4/25
60/60 [=====] - 0s 4ms/step - loss: 0.5250 - accuracy: 0.7617 - val_loss: 0.4596 - val_accuracy: 0.8300
Epoch 5/25
60/60 [=====] - 0s 4ms/step - loss: 0.4696 - accuracy: 0.7850 - val_loss: 0.4691 - val_accuracy: 0.8200
Epoch 6/25
60/60 [=====] - 0s 4ms/step - loss: 0.4368 - accuracy: 0.8167 - val_loss: 0.4172 - val_accuracy: 0.8100
Epoch 7/25
60/60 [=====] - 0s 4ms/step - loss: 0.3975 - accuracy: 0.8400 - val_loss: 0.4008 - val_accuracy: 0.8500
Epoch 8/25
60/60 [=====] - 0s 5ms/step - loss: 0.4398 - accuracy: 0.8183 - val_loss: 0.4524 - val_accuracy: 0.8200
Epoch 9/25
60/60 [=====] - 0s 4ms/step - loss: 0.3934 - accuracy: 0.8283 - val_loss: 0.4227 - val_accuracy: 0.8500
Epoch 10/25
60/60 [=====] - 0s 5ms/step - loss: 0.3972 - accuracy: 0.8417 - val_loss: 0.4117 - val_accuracy: 0.8200
Epoch 11/25
60/60 [=====] - 0s 4ms/step - loss: 0.3299 - accuracy: 0.8583 - val_loss: 0.5805 - val_accuracy: 0.7800
Epoch 12/25
60/60 [=====] - 0s 4ms/step - loss: 0.3207 - accuracy: 0.8667 - val_loss: 0.4104 - val_accuracy: 0.8400
Epoch 13/25
60/60 [=====] - 0s 5ms/step - loss: 0.2642 - accuracy: 0.8967 - val_loss: 0.4879 - val_accuracy: 0.8200
Epoch 14/25
60/60 [=====] - 0s 4ms/step - loss: 0.2423 - accuracy: 0.8983 - val_loss: 0.5029 - val_accuracy: 0.7800
Epoch 15/25

File failed to load: /experiments/mnist.0.7800

```
60/60 [=====] - 0s 4ms/step - loss: 0.2292 - accuracy: 0.9100 - val_loss: 0.5861 - val_accuracy: 0.8000
Epoch 16/25
60/60 [=====] - 0s 4ms/step - loss: 0.2045 - accuracy: 0.9333 - val_loss: 0.6261 - val_accuracy: 0.8600
Epoch 17/25
60/60 [=====] - 0s 5ms/step - loss: 0.1661 - accuracy: 0.9417 - val_loss: 0.6910 - val_accuracy: 0.8600
Epoch 18/25
60/60 [=====] - 0s 4ms/step - loss: 0.1427 - accuracy: 0.9433 - val_loss: 0.6651 - val_accuracy: 0.8300
Epoch 19/25
60/60 [=====] - 0s 4ms/step - loss: 0.1289 - accuracy: 0.9533 - val_loss: 0.8090 - val_accuracy: 0.8400
Epoch 20/25
60/60 [=====] - 0s 4ms/step - loss: 0.1526 - accuracy: 0.9417 - val_loss: 0.6510 - val_accuracy: 0.8600
Epoch 21/25
60/60 [=====] - 0s 4ms/step - loss: 0.1275 - accuracy: 0.9467 - val_loss: 0.8763 - val_accuracy: 0.8100
Epoch 22/25
60/60 [=====] - 0s 4ms/step - loss: 0.0954 - accuracy: 0.9650 - val_loss: 0.9162 - val_accuracy: 0.8400
Epoch 23/25
60/60 [=====] - 0s 4ms/step - loss: 0.1079 - accuracy: 0.9550 - val_loss: 0.8502 - val_accuracy: 0.8000
Epoch 24/25
60/60 [=====] - 0s 4ms/step - loss: 0.0596 - accuracy: 0.9833 - val_loss: 1.0537 - val_accuracy: 0.8100
Epoch 25/25
60/60 [=====] - 0s 4ms/step - loss: 0.0496 - accuracy: 0.9800 - val_loss: 1.0707 - val_accuracy: 0.8200
```

7. Comparar el rendimiento de las dos redes neuronales en el conjunto test mediante sus curvas ROC y las métricas de calidad.

Empezamos haciendo una funcion con la que podremos ver las curvas ROC de ambos modelos

```
In [50]: #plot accuracy and loss
def plot_prediction(n_epochs, mfit):
    N = n_epochs
    plt.style.use("ggplot")
    fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(15,6))
    fig.suptitle('Training Loss and Accuracy')

    ax1.plot(np.arange(0, N), mfit.history["accuracy"], label="train")
    ax1.plot(np.arange(0, N), mfit.history["val_accuracy"], label="val")
    ax1.set_title("Accuracy")
    ax1.set_xlabel("Epoch #")
    ax1.set_ylabel("Accuracy")
    ax1.legend(loc="lower right")

    ax2.plot(np.arange(0, N), mfit.history["loss"], label="train")
    ax2.plot(np.arange(0, N), mfit.history["val_loss"], label="val")
    ax2.set_title("Loss")
    ax2.set_xlabel("Epoch #")
    ax2.set_ylabel("Loss")
    ax2.legend(loc="upper right")

    plt.show()
```

Imprimimos el primer grafico de la primer a red neuronal

```
In [51]: plot_prediction(n_epochs, mfit_1)
```



Imprimimos el grafifco de la segunda red neuronal

File failed to load: /extensions/MathZoom.js

```
In [52]: plot_prediction(n_epochs, mfit_2)
```



```
In [53]: test_eval_1 = model_1.evaluate(x_test, y_test, verbose=1)
test_eval_2 = model_2.evaluate(x_test, y_test, verbose=1)

print('Test 1 loss:', test_eval_1[0]), print('Test 2 loss:', test_eval_2[0])
print('Test 1 accuracy:', test_eval_1[1]), print('Test 2 accuracy:', test_eval_2[1])
```

```
4/4 [=====] - 0s 5ms/step - loss: 0.9218 - accuracy: 0.8300
4/4 [=====] - 0s 4ms/step - loss: 1.0707 - accuracy: 0.8200
Test 1 loss: 0.9217840433120728
Test 2 loss: 1.0707391500473022
Test 1 accuracy: 0.8299999833106995
Test 2 accuracy: 0.8199999928474426
```

Out[53]: (None, None)

File failed to load: /extensions/MathZoom.js

Con esto comparamos tanto la primera red neuronal con la segunda, como podemos ver, tiene mejor predicción la primera CNN, ya que tiene un porcentaje de 83% de aciertos, en comparación con la segunda que honestamente no hay gran diferencia entre ellas que es de un 82%